无界探索：开放世界智能体挑战赛

智能体测评计分规则

第一条　总则与基本概念

(1) **适用范围**。本规则适用于对 Agent 在 MineDojo 的 Minecraft 1.11.2 测试环境中的一次完整测评。“环境”指提供 `env.step` 接口的测试环境。

(2) **种子与单局**。评测方预先确定 $N \geq 1$ 个隐藏随机种子，每个种子对应一个测试世界。Agent 在某一测试世界中从开始到终止的完整过程称为*一局*。各局独立进行、独立计分；每局开始时，Agent 应使用相同的初始配置，包括相同的代码、模型版本、提示词、可用工具和外部记忆初始快照。除最终成绩计算和作弊相关规则外，本规则其余内容均针对某一局。

(3) **环境步与累计步数**。一次对 `env.step` 的底层调用称为一个*环境步*。从测试世界初始化完成后的首次环境动作起，环境步依次编号为第 $1, 2, 3, \ldots$ 步。截至某一环境步（含该步）已执行的环境步总数，称为*累计步数*。每次实际执行的 `env.step` 调用均计一步，包括技能内部展开的动作、空操作、无效动作和失败重试。累计步数在一局内连续计数，死亡后继续累计。

(4) **实际运行时间**。*实际运行时间*指自该局测评开始起的墙钟（端到端）时间，包含 LLM 推理、模型调用等一切耗时，用于第五条的时限判定。LLM 推理、模型调用和 Token 消耗不计入累计步数，也不直接计分。

(5) **Token 消耗**。*Token 消耗*指一局中 Agent 通过官方指定的 LLM 调用端口发起的全部 LLM 调用所消耗的 token 累计总数，以比赛官方统一指定 API 平台的计数结果为准；参赛方自行统计的数值仅供参考，与平台计数不一致时以平台计数为准。每局的 Token 消耗上限为 5,000,000 token（5M），各局独立累计、互不累加，用于第五条的上限判定。

(6) **合法获得**。物品进入 Agent 的背包或装备栏，且同时满足下列条件时，称为*合法获得*：

   (i) 通过正常的游戏内采集、制作、拾取或其他合法途径获得；

   (ii) 获得事实由环境状态或物品获取事件确认；

   (iii) 未使用作弊命令、传送、直接修改背包或世界状态，或其他绕过正常环境交互的操作。

   若某物品先经不合法途径进入、其后又经合法途径首次获得，则以该合法获得的时刻为准。

(7) **事项、达成与达成步数**。里程碑（第二条）和支线任务（第三条）统称*事项*。某事项的*达成条件首次被满足*时，称该事项*达成*；达成该事项的环境步执行完毕时的累计步数，称为该事项的*达成步数*。里程碑 m 的达成步数记为 T_m，尚未达成时记 $T_m = +\infty$。

(8) **每项事项只计分一次**。每个事项仅在首次达成时计分，与达成顺序无关。达成后，相关物品被消耗、丢弃、破坏或因死亡丢失，或已放置的火把消失，均不撤销已得分数；重新获得同种物品也不重复计分。

(9) **单局得分构成**。一局的得分由三项得分和一项扣分构成：科技树分 S_{tech}（上限 55，第二条）、支线任务分 S_{side}（上限 5，第三条）、效率分 S_{eff}（上限 40，第四条）、死亡扣分 D（上限 10，第六条）。四项分数的合成公式见第七条。

(10) **概念与符号**。规则涉及的主要概念见表 1，步数类术语及其符号见表 2。

表 1: 主要概念

概念	含义	数量	作用
里程碑	具体的目标物品（如木镐、铁镐），每项有固定分值，见表 3	11	决定科技树分；其达成步数用于确定检查点步数
阶段	对里程碑的分组：木制、石器、铁器	3	为里程碑分组
检查点	每个阶段设一个，由该阶段标志里程碑的达成步数确定，见表 5	3	决定效率分
支线任务	与科技树无关的附加任务：获得煤炭或木炭、获得火把、放置火把，见表 4	3	决定支线任务分
补分项	获得铁镐时尚未达成的里程碑	—	补足科技树分，见第二条

表 2: 步数类术语与符号

术语	符号	对应对象	含义
环境步	—	一局	一次 `env.step` 调用
累计步数	—	一局	截至某一环境步（含该步）已执行的环境步总数
达成步数	T_m	里程碑 m	达成该里程碑的环境步执行完毕时的累计步数；尚未达成记 $+\infty$
检查点步数	$C_{\text{木}}$, $C_{\text{石}}$, $C_{\text{铁}}$	检查点	由标志里程碑的达成步数确定，用于效率分，见第四条
参考步数	$B_{\text{木}}$, $B_{\text{石}}$, $B_{\text{铁}}$	检查点	效率分公式中的参考值，见表 5

第二条　里程碑与科技树分

(1) **里程碑**。里程碑共 11 项，分属木制、石器、铁器三个阶段。每项里程碑 m 对应一种目标物品和一个里程碑分值 p_m，见表 3。目标物品被合法获得时，该里程碑达成，达成步数为 T_m。

(2) **目标物品的识别**。原木接受 1.11.2 支持的所有原木树种；对其余目标物品，同一物品标识符的各变种均视为满足目标物品（例如任意种类的木板）。

(3) **科技树分**。科技树分 S_{tech} 按下式确定，其中 $\mathcal{A}$ 为已达成里程碑的集合：

$$S_{\text{tech}} = \begin{cases} \displaystyle\sum_{m \in \mathcal{A}} p_m, & \text{尚未合法获得铁镐,} \\ 55, & \text{已合法获得铁镐.} \end{cases}$$

(4) **补分项**。合法获得铁镐时尚未达成的里程碑称为*补分项*。补分项按分值计入科技树分（即上式取 55），其达成步数仍为 $+\infty$。

表 3: 里程碑、目标物品与里程碑分值

阶段	里程碑	目标物品	里程碑分值 p_m
木制	原木	`log/log2`	2
	木板	`planks`	2
	木棍	`stick`	2
	工作台	`crafting_table`	4
	木镐 ⋆	`wooden_pickaxe`	5
石器	圆石	`cobblestone`	4
	石镐 ⋆	`stone_pickaxe`	6
	熔炉 ⋆	`furnace`	5
铁器	铁矿石	`iron_ore`	6
	铁锭	`iron_ingot`	7
	铁镐 ⋆	`iron_pickaxe`	12

注：带 ⋆ 者为标志里程碑（见第四条）。

第三条　支线任务分

(1) **支线任务**。支线任务共 3 项，分值及达成条件见表 4。

表 4: 支线任务、分值与达成条件

支线任务	分值	达成条件
获得煤炭或木炭	2	首次合法获得 `coal`（煤炭与木炭共用该标识符，获得任一即可，仅计一次）
获得火把	1	首次合法获得普通火把（`torch`）
放置火把	2	首次有效放置普通火把（`torch`）

(2) **有效放置火把**。指 Agent 通过合法环境动作，在游戏世界中成功放置一支普通火把，且该放置由环境状态变化或方块放置事件确认。

(3) **支线任务分**。支线任务分 S_{side} 为所有已达成的支线任务的分值之和。

第四条　效率分与检查点

(1) **检查点**。效率分 S_{eff} 仅取决于木制、石器、铁器三个检查点的检查点步数 $C_{\text{木}}, C_{\text{石}}, C_{\text{铁}}$。每个检查点由所在阶段的标志里程碑确定，参考步数 B 和满分权重见表 5。

表 5: 检查点、标志里程碑与效率分参数

阶段	检查点	标志里程碑	检查点步数	参考步数 B	满分权重
木制	木制检查点	木镐	$C_{\text{木}}$	$B_{\text{木}} = 1500$	8
石器	石器检查点	石镐和熔炉	$C_{\text{石}}$	$B_{\text{石}} = 6000$	12
铁器	铁器检查点	铁镐	$C_{\text{铁}}$	$B_{\text{铁}} = 36000$	20

(2) **检查点步数的计算**。三个检查点步数按下式计算，其中 T 为标志里程碑的达成步数：

$$
\begin{aligned}
C_{\text{铁}} &= T_{\text{铁镐}}, \\
C_{\text{石}} &= \min\bigl(\max(T_{\text{石镐}},\, T_{\text{熔炉}}),\; C_{\text{铁}}\bigr), \\
C_{\text{木}} &= \min\bigl(T_{\text{木镐}},\; C_{\text{石}}\bigr).
\end{aligned}
$$

(3) **效率分公式**。

$$
\boxed{S_{\text{eff}} = 8\,\frac{B_{\text{木}}}{B_{\text{木}} + C_{\text{木}}} + 12\,\frac{B_{\text{石}}}{B_{\text{石}} + C_{\text{石}}} + 20\,\frac{B_{\text{铁}}}{B_{\text{铁}} + C_{\text{铁}}}}
$$

其中参考步数 B 见表 5。当 $C = +\infty$ 时，对应的比值 $B/(B + C)$ 取 0。

第五条　测评终止

(1) **终止条件**。一局在下列情形之一发生时终止，并结算该局得分：

(i) 首次合法获得铁镐：该局立即终止，终止发生在获得铁镐的环境步执行完毕之后；

(ii) 尚未获得铁镐，且实际运行时间达到预先设定的 3600 秒时限。时限到达时立即终止，当前未完成的环境步不计；

(iii) 尚未获得铁镐，且该局 Token 消耗累计达到 5,000,000 token 上限。上限到达时立即终止，当前未完成的环境步不计，触达上限的那次 LLM 调用所产生的后续动作不再执行。

(2) **终止步内的事项**。在获得铁镐的环境步内确认的所有事项（含铁镐本身）均视为在终止前达成，全部计分。

(3) **结算范围**。按终止前已达成的事项结算，终止之后发生的事件不计分。

第六条　死亡与死亡扣分

(1) **复活**。Agent 死亡后允许在同一测试世界中复活，不得重新生成世界、回滚状态或修改种子。`keepInventory` 未启用，因此死亡后 Agent 的背包和装备栏的物品将会掉落。

(2) **死亡扣分**。设该局终止前 Agent 的死亡次数为 d（以环境确认的死亡事件计，终止步内发生的死亡亦计入）。死亡扣分为

$$D = \min(2d,\ 10).$$

第七条　最终得分

(1) **单局得分**。对每个隐藏种子，其单局得分为

$$S = \mathrm{clip}\big(S_{\mathrm{tech}} + S_{\mathrm{side}} + S_{\mathrm{eff}} - D,\ 0,\ 100\big),$$

其中 $\mathrm{clip}(x, a, b) = \min(\max(x, a), b)$，即将 x 限制在 a 至 b 之间。

(2) **最终成绩**。设各隐藏种子独立计分后的得分为 $S_1, \ldots, S_N$，Agent 的最终成绩为算术平均：

$$S_{\mathrm{final}} = \frac{S_1 + S_2 + \cdots + S_N}{N}.$$

(3) **不舍入**。整个计分过程中不进行任何舍入。

第八条　作弊

(1) **作弊**。下列行为称为作弊：

(i) **违规联网**。除通过官方指定的 LLM 调用端口进行推理与模型调用外，Agent 或参赛方以其他任何方式接入网络的行为。包括但不限于：联网访问种子库、地图服务、矿物定位服务、在线攻略或知识库；将本局地形、画面、状态上传至云端进行逆向反解、种子推断或矿物定位；调用云端 OCR、视觉、规划或模型训练/推理服务；其他以获取不公平优势、规避规则限制或影响测评公正性为目的的联网行为。

(ii) **违规读取或修改环境**。绕过 `env.step` 接口，直接读取、修改或影响环境内部数据的行为。包括但不限于：直接读写背包、装备栏、方块、实体、世界状态、时间、种子、存档、内存、日志、事件流或回放；使用作弊命令、传送、直接生成或删除物品。

(iii) **规避规则限制**。通过重新生成世界、回滚状态、修改种子、多进程或多实例并行试错等方式，规避死亡、时限、累计步数或其他规则限制的行为。

(iv) **人工介入**。由人直接或间接代替 Agent 完成环境交互或决策的行为。包括但不限于：人工提示、纠正、代打、遥控操作，以及使用外部程序、脚本或其他手段代替 Agent 执行环境动作。

(v) **篡改记录**。篡改、伪造、删除或选择性提交环境状态、物品获取事件、死亡事件、日志、回放、计分数据或其他测评记录的行为。

(vi) **其他明显不合理行为**。其他违反本规则、破坏测评公平性或利用漏洞获取不公平优势的行为。

(2) **允许的本地工具**。在本地运行、不涉及网络访问、不直接读取或修改环境内部数据、不代替 Agent 执行环境动作的工具，包括计算、搜索、规划、本地 OCR、离线预计算、通用知识库，以及基于合法观测进行的地形或种子推断等，不因本条本身而被认定为作弊；但其使用结果不得违反本规则其他条款。

(3) **多 Agent 补充条款**。被测 Agent 内部可以采用多模块、多角色或多 Agent 架构，但对外视为一个 Agent；环境动作必须由该 Agent 自身通过规定接口发起，否则按作弊处理。

(4) **作弊的认定**。作弊以环境状态、事件记录、日志、回放、接口调用记录及其他可复核证据为依据。组委会有权对疑似作弊行为进行调查、要求参赛方说明，并依据证据作出认定。

(5) **作弊的计分处置**。经认定发生作弊的，按下列方式处理：

   (i) 涉及作弊的单局，其单局得分记为 0，该局已达成事项、效率分及支线任务分均不计入成绩；

   (ii) 同一参赛方在多个种子或多个局中实施或参与作弊的，相关各局单局得分均记为 0，并按第七条重新计算最终成绩；

   (iii) 作弊行为在成绩公布后被查出的，组委会有权撤销相关成绩、名次或奖项，并重新公布结果。

(6) **进一步处理**。组委会有权根据作弊行为的性质、范围、主观故意及影响程度，采取包括但不限于取消参赛资格、取消全部成绩、追回奖项、禁止参加后续赛事等措施；构成违法的，依法处理。组委会保留对本条及作弊行为的进一步解释和处理权力。

第九条　附则

本规则未尽事宜由组委会另行解释，组委会保留对本规则的最终解释权。